Universidad Externado de Colombia

Departamento de Matemáticas

Pregrado en Ciencia de Datos

Proyecto Integrador: Segunda Entrega

Implementación de un método Gauss-Newton libre de derivadas para mínimos cuadrados no lineales

Artículo base: A derivative-free Gauss-Newton method (Cartis y Roberts, 2019)

Integrantes:

David Castro

Alejandro Pardo

Tomás Rincón

Curso: Métodos Numéricos

Docente: Edwin Fernando Muñoz

Bogotá, 2026

1. Introducción y cambios respecto a la primera entrega

Implementamos una versión simplificada de DFO-GN para minimizar $f(x) = \frac{1}{2}\|r(x)\|^2$ sin derivadas de r, y la comparamos con métodos que sí las usan o las aproximan. Atendemos las cuatro observaciones de la retroalimentación: **problemas de prueba** definidos (sección 3), **tolerancias** explícitas (sección 3), **generación del ruido** precisada (sección 3) y **elementos conservados** del algoritmo original (Tabla 1).

También hacemos un ajuste al plan: además del punto de Cauchy comprometido, agregamos un paso de Gauss-Newton con QR, porque los resultados mostraron que Cauchy no alcanza alta precisión. El método de Gauss-Newton se construye a partir de mínimos cuadrados con QR y la linealización del método de Newton.

2. Implementación

Todos los métodos de región de confianza comparten un solo núcleo, que combina el **origen de J** con el **tipo de paso**. Así, cada comparación aísla un solo efecto. El álgebra es propia; NumPy almacena los datos y SciPy solo valida.

- **Jacobiano por interpolación (ec. 2.4).** Con n+1 puntos se plantea $W\,J^T = D$, donde W tiene filas $y_t - x_k$. Los m residuos comparten W, de modo que una eliminación de Gauss con pivoteo parcial resuelve todos los lados derechos. La razón entre el menor y el mayor pivote de W/Δ vigila la geometría: si baja de 10^{-8}, los puntos se reconstruyen.
- **Paso de Cauchy.** Es $s = -t\,g$ con $t = \min(g^Tg/g^THg,\ \Delta/\|g\|)$, $g = J^Tr$ y $H = J^TJ$: descenso del gradiente con la tasa óptima para el modelo.
- **Paso QR.** Resuelve $\min\|Js + r\|$ con Gram-Schmidt modificado y $Rs = -Q^Tr$, evitando las ecuaciones normales, que elevan al cuadrado el condicionamiento. Se recorta a Δ. Una primera versión, solo recortada, se detuvo en $f \approx 32$ en Freudenstein & Roth (mínimo: 24.49), porque con J casi singular puede incumplir el decrecimiento de Cauchy (ec. 2.8). Por eso se elige el paso, QR o Cauchy, que más baje el modelo.
- **Comparadores.** GN con J exacto; GN con diferencias finitas hacia adelante ($h = \sqrt{\varepsilon}\cdot\max(1, |x_j|)$); y descenso del gradiente con η fija, escogida como la mejor de $\{10^{-1}, \ldots, 10^{-5}\}$ para cada problema sin ruido, lo que favorece a este método.

Tabla 1. Elementos del Algoritmo 1 del artículo en nuestra versión.

Elemento	Estado	Justificación
Modelo lineal por interpolación (2.2–2.4) y modelo de f (2.5)	Conservado	Idea central del método
Región de confianza, cociente R_k con $\eta_1 = 0.1$ y $\eta_2 = 0.7$	Conservado	Controla la confianza en el modelo
Actualización de Δ_k (2.15)	Simplificado (sin ρ_k)	Reduce parámetros
Parada (sección 4.3): f pequeña, $\Delta < 10^{-10}$, presupuesto	Conservado	Comparabilidad
Subproblema (rutina tipo DFBOLS/BOBYQA)	Sustituido por Cauchy o QR	Cumple la condición 2.8 del artículo
Geometría (Λ-poised)	Simplificado: razón de pivotes y reconstrucción	Criterio más simple de implementar
Fases de criticidad y de seguridad, radio ρ_k	Omitidos	Simplificación; efecto discutido en sección 5
Actualización de factorización (sección 4.4)	Omitido	Con $n \leq 6$ resolver desde cero es barato

Validación. `gauss` y `QR` coinciden con NumPy en 200 sistemas aleatorios (error de QR y de ortogonalidad $\leq 8 \cdot 10^{-16}$). Los siete problemas reproducen el $2f(x_0)$ de la Tabla 2 del artículo; J analítico coincide con diferencias centradas (error relativo $\leq 2.4 \cdot 10^{-10}$); y `scipy.optimize.least_squares` reproduce los 2f*.

3. Diseño experimental

Problemas (Tabla 2 del artículo, de Moré, Garbow y Hillstrom, 1981; Pk es el problema k de esa tabla): P7 Rosenbrock (2,2), P13 Freudenstein & Roth (2,2; residuo no nulo), P9 Helical Valley (3,3), P15 Bard (3,15), P11 Powell Singular (4,4; J singular en la solución), P17 Kowalik & Osborne (4,11) y P19 Watson (6,31).

Tolerancias. Métrica del artículo (ec. 5.1): $N(\tau)$ es el número de evaluaciones de r hasta $f(x_k) \leq f + \tau(f(x_0) - f)$, con $\tau \in \{10^{-1}, 10^{-3}, 10^{-5}\}$. Presupuesto: $200(n+1)$ evaluaciones.

Ruido (sección 5.2 del artículo). Multiplicativo $\tilde{r}_i = r_i(1+\varepsilon)$ y aditivo $\tilde{r}_i = r_i+\varepsilon$, con $\varepsilon \sim N(0, \sigma^2)$, $\sigma = 10^{-2}$, independiente por componente y evaluación. Diez corridas con `np.random.default_rng(2026+k)`. El algoritmo solo ve el valor ruidoso; la métrica se mide con f real. No incluimos el ruido χ^2 del artículo. El cuaderno `03_experimentos.ipynb` regenera todas las tablas y figuras; dos ejecuciones dieron resultados idénticos, salvo los tiempos.

4. Resultados y comparación

Tabla 2. N(τ = 10^{-5}) sin ruido: evaluaciones de r (— = no alcanzado). GN exacto requiere además J; DG usa J exacto.

Problema	DFO-GN QR	DFO-GN Cauchy	GN exacto QR	GN exacto Cauchy	GN dif. finitas QR	DG
P7 Rosenbrock	71	—	29	—	71	—
P13 Freudenstein & Roth	157	—	19	—	45	—
P9 Helical Valley	55	633	16	457	52	—
P15 Bard	14	—	6	—	24	—
P11 Powell Singular	26	371	7	214	35	729
P17 Kowalik & Osborne	35	—	8	—	36	—
P19 Watson	33	—	8	—	56	—

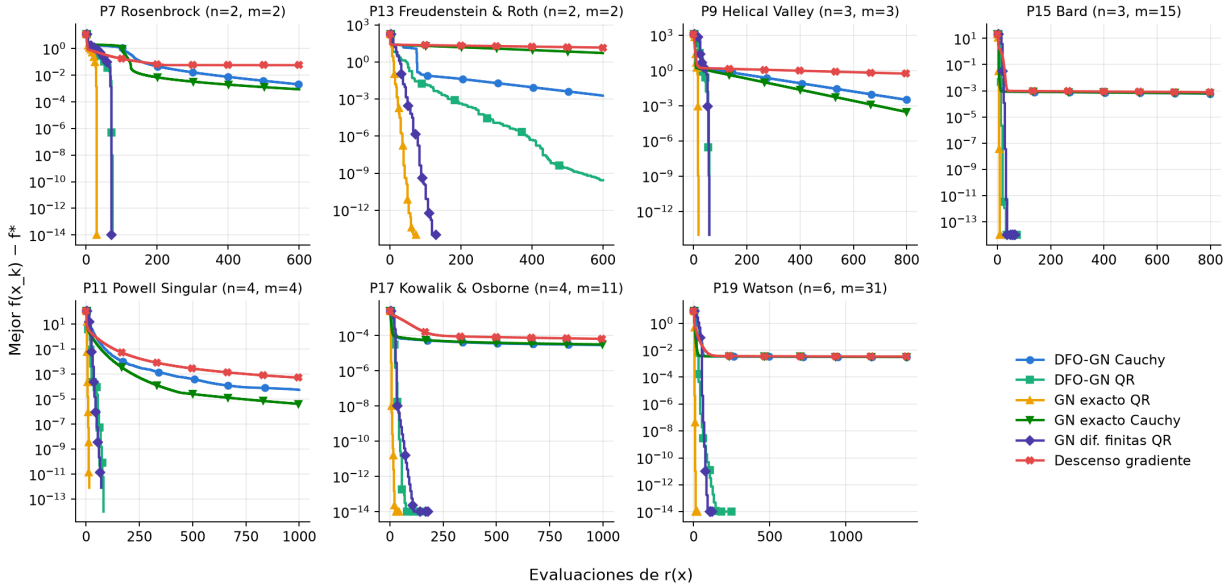


Figura 1. Convergencia sin ruido: mejor $f(x_k) - f^*$ contra evaluaciones de r.

El paso limita más que el origen de J. La Tabla 2 y la Figura 1 muestran que Cauchy alcanza τ = 10^{-5} solo en 2 de 7 problemas, con J interpolado o exacto, y sus curvas son paralelas a las del descenso del gradiente: tener derivadas exactas no lo rescata. Es coherente, porque Cauchy es un paso de máximo descenso. Con QR, en cambio, DFO-GN resuelve los 7 problemas.

DFO-GN frente a diferencias finitas. Sin usar derivadas, DFO-GN QR necesitó menos evaluaciones en 4 de 7 problemas (Bard, Powell, Kowalik, Watson), empató en Rosenbrock y necesitó más en Helical Valley (por poco) y Freudenstein & Roth (3.5 veces). Reutilizar puntos cuesta 1.3–3.2 evaluaciones por iteración, frente a 1.9–5.0, pero exige más iteraciones.

Orden de convergencia. Con $e_k = \|x_k - x^*\|$, GN exacto muestra p ≈ 1.0 en Bard, Powell Singular, Kowalik y Watson, lo esperable con residuo no nulo o J singular. En

Rosenbrock y Helical Valley hay muy pocos iterados en la zona asintótica para estimarlo, y en Freudenstein & Roth y en DFO-GN el estimador fue inestable, por lo que no sacamos conclusión.

Tabla 3. Corridas con éxito, de 70 (7 problemas × 10 semillas), multiplicativo / aditivo.

Método	$\tau = 10^{-1}$	$\tau = 10^{-3}$	$\tau = 10^{-5}$
DFO-GN QR	49 / 51	38 / 35	25 / 14
DFO-GN Cauchy	24 / 22	12 / 12	0 / 0
GN dif. finitas QR	0 / 0	0 / 0	0 / 0
GN exacto QR (usa J exacto)	70 / 62	64 / 60	57 / 44
Descenso del gradiente (usa J exacto)	70 / 70	40 / 40	10 / 10

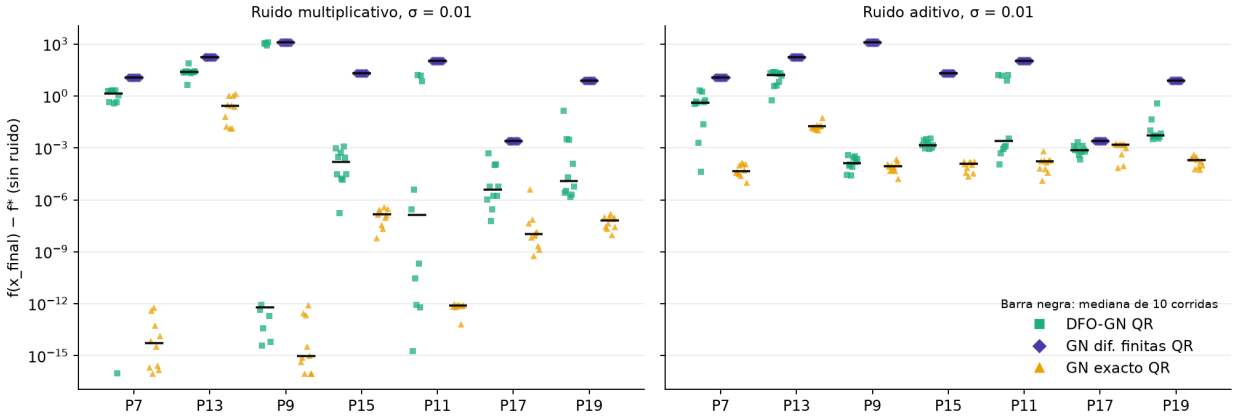


Figura 2. Brecha final con ruido por problema, en 10 corridas.

Robustez. Es el resultado más claro. GN con diferencias finitas fracasa en las 140 corridas y queda en $f(x_0)$ (Figura 2): con $h \approx 10^{-8}$ y $\sigma = 10^{-2}$, el ruido en J es del orden de $\sigma/h \approx 10^{6}$, lo que confirma la motivación del artículo. DFO-GN QR, también sin derivadas, sí progresa, aunque con mucha dispersión: en Helical Valley y Powell Singular la Figura 2 muestra corridas casi perfectas junto a otras que no avanzan. Los métodos con J exacto son una referencia, no una alternativa real, porque en un problema sin derivadas no están disponibles.

Tabla 4. Costo por iteración (rango entre problemas).

Método	Evaluaciones de r	Tiempo (ms)	Sistema resuelto
DFO-GN QR	1.32–3.20	0.25–0.77	Gauss n×n con m lados derechos + QR m×n
GN exacto QR	1.00 (+ J)	0.15–0.42	QR m×n
GN dif. finitas QR	1.87–5.00	0.16–0.52	QR m×n

La iteración de DFO-GN QR tarda más en tiempo de pared, porque hace Gauss y QR. Esto importa poco cuando r es costosa, que es el caso de interés: ahí domina el número de evaluaciones.

5. Análisis preliminar

Fortalezas. DFO-GN QR converge a los valores de referencia en los 7 problemas sin derivadas y, a diferencia de las diferencias finitas, tolera el ruido.

Limitaciones. (i) Cauchy solo no basta para alta precisión. (ii) Freudenstein & Roth consume todo el presupuesto, un problema con residuo no nulo. (iii) Con ruido, entre 60 y 70 de las 70 corridas de DFO-GN QR terminan por radio pequeño: sospechamos que los rechazos causados por el ruido encogen Δ, de modo que el error de J ($\approx \sigma/\Delta$) crece. El radio ρ_k que omitimos existe justamente para acotar esa reducción; aún no lo hemos comprobado experimentalmente. (iv) Siete problemas no permiten generalizar.

Tabla 5. Artículo frente a nuestra implementación.

Aspecto	Artículo	Nosotros	Consecuencia
Problemas	53	7	Sin perfiles de datos; comparación por problema
Comparadores	BOBYQA, DFBOLS, POUNDERS	GN exacto, GN-DF, DG	**No podemos contrastar** su ventaja de tiempo (7 a 444 veces frente a Py-DFBOLS)
Subproblema	Rutina DFBOLS/BOBYQA	Cauchy o QR + Cauchy	Cauchy solo es más lento
Geometría	Λ-poised	Razón de pivotes	Implementación simple; posiblemente más evaluaciones
Protección de Δ	ρ_k	Ninguna	Probable pérdida de robustez con ruido

Nuestros resultados apoyan la motivación del artículo: la interpolación cuesta un número de evaluaciones comparable al de las diferencias finitas, sin fracasar con ruido. El artículo no hace esta comparación, sino que enfrenta a DFO-GN con otros métodos sin derivadas, de modo que no reproducimos sus cifras.

Mejoras para la entrega final. Incorporar ρ_k y medir su efecto con ruido (prioritaria); añadir los tiempos con r costosa simulada; probar más problemas y perfiles de datos; analizar el ruido con las herramientas de Monte Carlo (S25–S27).

6. Conclusiones preliminares

- Interpolar J con Gauss y dar el paso con QR produce un método sin derivadas que resuelve los 7 problemas a $\tau = 10^{-5}$ sin ruido.
- La elección del paso pesa más que el origen de J: Cauchy limita incluso con derivadas exactas.
- Con ruido, las diferencias finitas fracasan por completo y DFO-GN conserva capacidad de avance, aunque irregular.
- La mejora prioritaria es proteger el radio frente al ruido.

Declaración de uso de inteligencia artificial

Usamos Claude (Anthropic), modelo Claude Opus 5.5, como apoyo en la redacción inicial del código en Python, la propuesta de los experimentos y el primer borrador de este informe. Los resultados provienen de la ejecución del código. Como grupo, analizamos línea por línea que todo siguiera los lineamientos del curso.

Referencias

- Cartis, C., & Roberts, L. (2019). A derivative-free Gauss-Newton method. Mathematical Programming Computation, 11, 631–674.
- Moré, J. J., Garbow, B. S., & Hillstrom, K. E. (1981). Testing unconstrained optimization software. ACM TOMS, 7(1), 17–41.
- Moré, J. J., & Wild, S. M. (2009). Benchmarking derivative-free optimization algorithms. SIAM Journal on Optimization, 20(1), 172–191.
- Nocedal, J., & Wright, S. J. (2006). Numerical Optimization (2.ª ed.). Springer.
- Turner, P. R., Arildsen, T., & Kavanagh, K. (2018). Applied Scientific Computing With Python. Springer.

Anexo: código

Tres cuadernos ejecutables en Colab o Jupyter, en la carpeta `Segunda_Entrega/cuadernos` de https://github.com/AlejandroP212/metodos-numericos-dfo-gn : `01_metodos_y_validacion`, `02_dfogn_y_comparadores` y `03_experimentos`.